

UNIVERSIDAD COMPLUTENSE DE MADRID
MÁSTER EN BIG DATA, DATA SCIENCE E INTELIGENCIA
ARTIFICIAL



UNIVERSIDAD
COMPLUTENSE
MADRID

nticmaster

**Modelo de predicción de riesgo de lesión o
malestar psicológico o crisis asmática por
carga de actividad física registrada en
relojes inteligentes**

TRABAJO FIN DE MÁSTER (TFM)

Autor/a: Ana Irina Calvo Carvajal
Tutores: Carlos Ortega y Santiago Mota
Modalidad: Análisis de Dataset y Pipeline (Orientación Data Scientist)

Madrid, Septiembre, 2026

Índice

1 Introducción.....	2
1.1. Contexto y Justificación del caso de uso.....	2
1.2. Objetivos.....	3
1.2.1. Objetivo General.....	3
1.2.2. Objetivos Específicos.....	3
1.3. Metodología.....	3
2 Descripción del Conjunto de Datos.....	4
2.1. Selección del dataset poblacional.....	4
2.2. Definición de Variables.....	4
2.2.1 Variables explicativas.....	4
2.2.2 Variables objetivo.....	5
2.3. Análisis Exploratorio de Datos (EDA) y estadística descriptiva.....	5
3 Preparación de Datos.....	6
3.1. Limpieza, tratamiento de nulos y cuestionario del CDC.....	6
3.2. Feature Engineering.....	6
4 Modelización Analítica.....	7
4.1. Selección de algoritmos de Machine Learning.....	7
4.2. Entrenamiento y ajuste de hiperparámetros.....	7
4.3. Validación y Comparación.....	8
4.3.1 GridSearchCV inicial con stratify compuesto.....	8
4.4.3 GridSearchCV con MultilabelStratifyShuffleSplit, balanceo y f2_score.....	9
5 Evaluación y Discusión de Resultados.....	11
5.1. Métricas de rendimiento.....	11
5.2. Explicatividad e interpretabilidad.....	12
6 Productivización y Arquitectura.....	13
6.1. Justificación de arquitectura.....	13
6.2. Acceso al modelo.....	13
6.3. Diseño del pipeline en AWS.....	14
7 Conclusiones.....	17
7.1. Conclusiones e impacto de negocio.....	17
7.2. Limitaciones.....	18
7.3. Mejoras futuras del producto.....	19
8. Bibliografía.....	19
Anexos.....	21
Apéndice A: Recursos Externos y Código.....	21
Apéndice B: Documentación Técnica de Soporte.....	22

1 Introducción

1.1. Contexto y Justificación del caso de uso

En la actualidad, es común que la mayoría de la población interactúe con tecnología IoT, que registra datos personales de manera continua. Una de dichas tecnologías es los relojes inteligentes, que suelen tener acceso a datos biométricos y de actividad física, los cuales se utilizan para determinar niveles de actividad física personal, así como alimentar planes de entrenamiento deportivo. Sin embargo, estos datos suelen empujar al usuario a realizar mayor actividad, sin tener en cuenta diagnósticos médicos actuales o determinar cuándo la mejor opción es enfocarse en el descanso inmediato, para mejorar los indicadores de salud.

No es suficiente medir la cantidad de pasos diarios o el ritmo cardíaco para determinar la salud de una persona o decidir cómo modificar planes de entrenamiento para balancear mejor los esfuerzos y descansos. En un mundo donde los datos están al alcance de los dedos, debemos preguntarnos qué estamos haciendo con ellos además de almacenar petabytes en centros de datos.

La idea de este proyecto es utilizar datos que, como usuarios de relojes inteligentes, ya generamos, así como datos de perfiles de usuario que creamos en las aplicaciones de las compañías que manejan las marcas de dichos relojes, para obtener mayor beneficio en cuanto a nuestra salud: conocer si el nivel de esfuerzo o carga física realizada genera un riesgo ya sea de lesión deportiva, exacerbación de condiciones mentales crónicas como depresión o ansiedad, así como de crisis asmática respiratoria.

1.2. Objetivos

1.2.1. Objetivo General

Dada la carga de actividad física registrada por un usuario en un reloj inteligente y su perfil de salud, es posible predecir de forma eficaz su riesgo de sufrir una lesión deportiva, un episodio de malestar psicológico (depresión o ansiedad) o una crisis respiratoria asmática, mediante un modelo de machine learning productivizado como servicio accesible a compañías de relojes inteligentes.

1.2.2. Objetivos Específicos

1. Limpiar, preparar y transformar los datos de la encuesta anual National Health Interview Survey (NHIS) del Centers for Disease Control and Prevention (CDC) de EE.UU. correspondientes al año 2024, resolviendo la codificación de valores especiales y el branching propio del cuestionario.
2. Diseñar y construir, a partir de variables disponibles en la encuesta, las tres variables objetivo (1) riesgo de lesión deportiva, (2) riesgo de malestar psicológico y (3) riesgo de crisis respiratoria asmática, que no existen de forma directa en el dataset.
3. Entrenar, comparar y ajustar distintos algoritmos de machine learning para cada una de las variables objetivo, evaluando su rendimiento sobre un conjunto de datos de actividad física.
4. Diseñar una lógica de riesgo compuesto que combine los tres resultados individuales en un único score de riesgo general por usuario.
5. Productivizar el modelo resultante mediante una arquitectura en AWS desplegada con infraestructura como código y un pipeline de CI/CD, de forma que las compañías de relojes inteligentes puedan enviar la telemetría real de sus usuarios y obtener predicciones de riesgo a través de una API.

1.3. Metodología

Para lograr el objetivo acotado a la predicción de riesgo de lesiones deportivas, crisis de ansiedad, depresión o asma, se decide utilizar la modelización mediante algoritmos de machine learning, que logren ya sea clasificar o crear una calificación de riesgo. Además, se determina

que se requerirá la construcción de la variable objetivo a partir del dataset escogido. Una vez creado el modelo de machine learning, se productivizará mediante un pipeline que utilice un proceso de despliegue con Continuous Integration/Continuous Deployment (CI/CD), así como una arquitectura en el proveedor de servicios en la nube de Amazon AWS. Ya estando disponible en AWS, se creará un acceso mediante API para que las compañías de relojes inteligentes puedan enviar la telemetría de usuario y obtener sus predicciones de riesgo.

2 Descripción del Conjunto de Datos

2.1. Selección del dataset poblacional

Para seleccionar un dataset que permitiera la exploración y el entrenamiento de modelos con alta probabilidad de predecir el riesgo de las variables objetivo relacionadas con lesiones deportivas, exacerbaciones de ansiedad, depresión o asma, se estudiaron distintas fuentes como los datos públicos de Strava en Kaggle, y los que Centers for Disease Control and Prevention (CDC) pone a disposición del público tras realizar las encuestas [National Health And Nutrition Examination Survey \(NHANES\)](#) y [National Health Interview Survey \(NHIS\)](#) [2].

Inicialmente el alcance del proyecto incluía el estudio de las exacerbaciones de distintas enfermedades crónicas, pero por las características de los datos, se determinó que solo había posibilidad de predicción para lesiones deportivas, depresión, ansiedad y crisis asmáticas. Tras examinar las columnas disponibles en cada dataset, se determinó que NHIS para el año 2024 poseía los datos necesarios en cuanto a actividad física, así como para las variables objetivo ideales.

2.2. Definición de Variables

2.2.1 Variables explicativas

Las variables explicativas escogidas del dataset NHIS24, así como sus transformaciones, fueron las siguientes:

Tabla X. Variables numéricas y explicativas		
Numéricas	'AGEP_A', 'SLPHOURS_A', 'MODMIN_A', 'VIGMIN_A', 'MODFREQW_A', 'VIGFREQW_A', 'STRFREQW_A', 'HEIGHT_CM', 'MODMIN_WEEKLY', 'VIGMIN_WEEKLY'	edad Horas de sueño last 24h minutos act. moderada minutos act. vigorosa frecuencia act. moderada frecuencia act. vigorosa Frecuencia act. fuerza altura en cm minutos semanales act. mod. minutos semanales act. vigorosa
Catóricas	'ANXEV_A', 'DEPEV_A', 'ASEV_A', 'SEX_A', 'BMICAT_A', 'CANT_MODFREQW_A', 'CANT_VIGFREQW_A', 'CANT_STRFREQW_A', 'MOD_LEVEL', 'VIG_LEVEL'	diagnóstico ansiedad diagnóstico depresión diagnóstico asma sexo categoría índice masa corporal no puede act. moderada no puede act. vigorosa no puede act. fuerza nivel act. moderada semanal nivel act. vigorosa semanal

2.2.2 Variables objetivo

Una vez analizadas todas las columnas del dataset y realizado el análisis exploratorio de datos (EDA), se determinó que el dataset no tenía las variables objetivo necesarias para la aplicación de los algoritmos de machine learning, pero sí la información necesaria para construirlas a partir de columnas preexistentes. Se decidió crear una variable objetivo distinta para cada predicción: `y_lesion_deportiva` para lesiones deportivas, `y_malestar_psicologico` utilizando el modelo clínico Kessler K6 [2] para agrupar depresión y ansiedad, y `y_respiratorio` para crisis respiratoria. En la [Tabla B.4](#) se muestra la construcción de cada variable. Para evaluar el riesgo general de un usuario, se creó un algoritmo de scoring que está disponible en el script `risk_scoring.py`, que determina el riesgo compuesto una vez que la predicción de cada variable objetivo está lista. La lista completa de variables incluidas en el dataset inicial de NHIS24 se encuentra en el Apéndice [A.4](#).

2.3. Análisis Exploratorio de Datos (EDA) y estadística descriptiva

El dataset inicial tenía dimensiones (32629, 630). Luego de la preparación de datos y la partición train_test de 80/20, sus dimensiones fueron `X_train(26103, 16)` y `X_test(6526,`

16), con. Las distribuciones de nuestras variables objetivo fueron similares, concentradas en los niveles bajos: `y_lesion_deportiva`, variable binaria con una proporción de clases 0: 98.01% 1:1.92% , `y_malestar_psicologico`, variable ordinal 0-2 con 0: 78.57%, 1: 17.85%, 2: 3.58%, y `y_respiratorio`, variable binaria, con 0: 74.22% y 1: 25.78%, que además no participa del stratify inicial. Tras analizar la actividad física, también se determinó que un porcentaje significativo de la muestra reportaba baja o nula actividad física. Todo esto mostró un claro desbalance de clases que debió manejarse a la hora de modelar.

El proceso de análisis exploratorio de datos completo se encuentra disponible en el Jupyter notebook, en el apéndice [A.2](#).

3 Preparación de Datos

3.1. Limpieza, tratamiento de nulos y cuestionario del CDC

En cuanto a procedimientos de preparación de datos, se realizaron distintas transformaciones, imputaciones, recodificaciones y eliminación de valores faltantes. Una de las transformaciones más importantes al limpiar nuestro dataset fue la de reinterpretar las codificaciones de la encuesta de NHIS mediante las funciones `recode_nan`, `recode_zero` y `recode_incap` para usuarios con limitaciones para realizar un tipo de actividad. En especial, fue fundamental el lograr comprender no solo las codificaciones de la encuesta, sino su branching, ya que muchas preguntas podían saltarse o solo se realizaban a usuarios que habían respondido de cierta manera una pregunta anterior.

3.2. Feature Engineering

Para la construcción de columnas nuevas, se tomaron en cuenta algunas fuentes bibliográficas, así como las columnas ya procesadas durante la limpieza de datos de NHIS24. Para comparar nuestras filas con los resultados de investigaciones [1], era necesario crear una manera de clasificar el nivel de actividad física por fila. Para esto, se calcularon columnas de cantidad de tiempo de ejercicio semanal por tipo `MODMIN_WEEKLY`, `VIGMIN_WEEKLY`, así como columnas `MOD_LEVEL` y `VIG_LEVEL` con su clasificación por medio de bins `sin actividad/insuficiente/minimo/supera recomendación`. También se realizaron algunas transformaciones como pasar los datos de altura de pulgadas a centímetros (`HEIGHT_CM`) o la

implementación de una columna que mostrara la incapacidad del usuario de realizar algún tipo de actividad (`CANT_MODFREQW_A`, `CANT_VIGFREQW_A`, `CANT_STRFREQW_A`).

También se definió la estrategia de preprocesamiento a utilizar para las variables escogidas como un preprocesador que aplica transformaciones por columna dependiendo del tipo de dato, como podemos ver en la [Tabla B.1](#), aplicando `SimpleImputer`, `StandardScaler`, `RobustScaler`, `OneHotEncoder` y `OrdinalEncoder`. Los pasos de preparación de datos utilizados en el dataset NHIS24, además, generaron un subset de pasos a aplicar en los datos de prueba de telemetría provenientes de relojes inteligentes y sus sistemas de perfil de usuario, como puede observarse en el script `data_cleanup.py` utilizado por el sistema en producción.

4 Modelización Analítica

4.1. Selección de algoritmos de Machine Learning

Para la selección de algoritmos de Machine Learning se consideró la naturaleza de las variables objetivo a predecir. Se determinó la necesidad de utilizar algoritmos de clasificación binaria para los riesgos de lesión deportiva y de crisis asmática, y multiclase para el riesgo de malestar psicológico.

Se contempló el uso de un algoritmo de GridSearchCV inicial, que incluyera distintos tipos de algoritmos para determinar cuáles se ajustan mejor, así como obtener modelos con mayor estabilidad y precisión. Los algoritmos utilizados fueron RandomForestClassifier, SVM lineal, SVM gaussiano RBF y XGBoost.

4.2. Entrenamiento y ajuste de hiperparámetros

Una vez que encontramos los mejores modelos para las tres variables objetivo, se procedió a entrenarlos y ajustar los hiperparámetros correspondientes. Para los tres casos, se realizó este procedimiento para el mejor estimador de cada variable objetivo, así como para el segundo mejor estimador, ya que era aún posible que ajustando hiperparámetros se obtuviese un mejor resultado que sólo con el primer mejor estimador.

Dicha situación podemos verla con la variable objetivo `y_respiratorio`, en la cual obtuvimos RandomForest como mejor estimador del GridSearch inicial, pero al ajustar parámetros, el mejor algoritmo fue XGBoost.

En el caso de las otras dos variables objetivo, se observa que el algoritmo del mejor estimador en el GridSearch inicial se mantuvo luego del entrenamiento. Para `y_lesion_deportiva`, XGBoost fue el mejor algoritmo durante el GridSearch inicial, así como al final del ajuste de hiperparámetros, obteniendo un `roc_auc` de 0.7098 contra el `roc_auc` de 0.7080 de RandomForest. En el caso de `y_malestar_psicologico`, en cambio, RandomForest fue el claro ganador con un `f1_macro` de 0.5238, superando al modelo ajustado de XGBoost.

Sin embargo, luego de la validación de estos modelos contra el `X_test`, se obtuvieron métricas que se quisieron mejorar, por lo cual se procedió a hacer ajustes como la restratificación del dataset utilizando `MultilabelStratifyShuffleSplit` para distribuir mejor las clases, seleccionar mejores valores en los hiperparámetros de balanceo de clases `class_weight` y `scale_pos_weight`, así como la creación de una métrica de selección en GridSearch que no solo tomase en cuenta el accuracy, sino también el recall. Con los nuevos mejores estimadores, se obtuvieron mejores resultados como se observa en la sección de evaluación.

4.3. Validación y Comparación

4.3.1 GridSearchCV inicial con stratify compuesto


Para poder comparar los modelos luego del GridSearchCV inicial, se realizaron boxplots que mostraran la estabilidad de cada modelo. Para `y_lesion_deportiva` fue claro que aún cuando la mayoría obtenía un score similar, los modelos XGBoost, RandomForest y LinearSVC eran los mejores, por el tamaño de sus cajas y bigotes. Se puede encontrar el detalle en el Apéndice B (ver [Figura B.1](#)).

En el caso de `y_respiratorio`, el SVC gaussiano RBF fue el peor al considerar sus cuantiles; sin embargo, XGBoost y RandomForest tuvieron un buen comportamiento. Se puede encontrar el detalle en la [Figura B.2](#).

Para la variable `y_malestar_psicologico`, hubo un ganador claro en el mejor estimador de RandomForest, por lo que se procedió directamente a ajustar los hiperparámetros de ese algoritmo. Se puede encontrar el detalle en la [Figura B.3](#).


4.4.3 GridSearchCV con MultilabelStratifyShuffleSplit, balanceo y f2_score

Luego de comparar la estabilidad de estos modelos iniciales con los modelos generados por GridSearch con MultilabelStratifyShuffleSplit (MSSS), balanceo y f2_score, se observó que (1) en `y_lesion_deportiva` con f2_score, el modelo de LogisticRegression colapsa, sin embargo XGBoost y RandomForest se ven mucho más estables: cajas más angostas con buena distribución, aun cuando parecen tener un score menor, al lograr mejorar el recall. Además, al comparar esos dos modelos, es preferible RandomForest con MSSS y balanceo por su buen manejo de outliers, ya sea con o sin f2_score.




(2) Para `y_malestar_psicologico`, es claro que el modelo más estable es RandomForest, con mejoras en las versiones que usan el MultilabelStratifyShuffleSplit.

Figura 2: Comparación de `y_malestar_psicologico` de modelos MSS con balanceo y MSS con balanceo y f2_score



(3) Para `y_respiratorio`, vemos que los 3 GridSearch generan resultados relativamente similares. Sin embargo, podemos observar que RandomSearch con `f2_score` tiene una mejor distribución y manejo de outliers (vs XGBoost, que deja un outlier perdido en `f2_score`).




Los gráficos pueden ser consultados individualmente en el Apéndice B (ver [figuras B.4-B-9](#)).

5 Evaluación y Discusión de Resultados

5.1. Métricas de rendimiento

Los tres modelos de machine learning fueron evaluados sobre el subset `X_test`, con el que no fueron entrenados, eliminando los valores faltantes mediante una máscara llamada `notna_mask`. Se generaron las matrices de confusión para los modelos ganadores del GridSearch inicial sin MSSS (ver [Figura B.10](#)), y la tabla de resultados (ver [Tabla B.2](#)), pero fueron descartados al preferir el uso de los modelos con MSSS, mejor balanceo y selección basada en `f2_score`, dado que tenían mejor recall y precisión:

Tabla 1: Resultados de métricas						
version	var_obj	ganador	accuracy	recall	precision	score (f1/f2)
msss_bal	y_lesion_deportiva	XGBoost	0.915722	0.312000	0.077535	0.124204
msss_f2	y_lesion_deportiva	XGBoost	0.908213	0.344000	0.076786	0.125547
original	y_lesion_deportiva	XGBoost	0.980800	0.000000	0.000000	0.000000
msss_bal	y_malestar_psicologico	RandomForest	0.741474	0.560331	0.480233	0.493095
msss_f2	y_malestar_psicologico	RandomForest	0.741474	0.560331	0.480233	0.493095
original	y_malestar_psicologico	RandomForest	0.771600	0.527800	0.504800	0.511600
msss_bal	y_respiratorio	XGBoost	0.744017	0.012097	0.750000	0.023810
msss_f2	y_respiratorio	RandomForest	0.634755	0.608871	0.372840	0.462481
original	y_respiratorio	XGBoost	0.740600	0.027100	0.583300	0.051900



Al observar las matrices de confusión, así como las métricas de la tabla anterior, es evidente que la estratificación inicial y la falta de balance de clases, así como la métrica utilizada para seleccionar el mejor estimador de un grid, afectaron negativamente los resultados iniciales/originales.

En nuestro caso, al estar prediciendo riesgos relacionados con la salud, el recall toma una relevancia mayor, ya que se prefiere una mejor sensibilidad. Es más importante para nuestro producto acertar más casos reales de crisis que fallar en favor de la predicción del no evento.

5.2. Explicatividad e interpretabilidad

Al analizar no solo los boxplots de estabilidad, las matrices de confusión y los resultados de métricas, sino también el cálculo de importancia de features para la predicción de variables objetivo en los modelos seleccionados, se observa que para `y_lesion_deportiva` la importancia de las variables de minutos de actividad física vigorosa `VIG_MIN`, el diagnóstico de depresión `DEPEV_A` y la frecuencia de entrenamiento de fuerza `STRFREQW_A` suelen ser los features con mayor importancia. Sin embargo, para el caso de `y_malestar_psicologico`, dados nuestros datos de entrenamiento, los modelos encuentran mayor relevancia en los

diagnósticos clínicos `DEPEV_A` y `ANXEV_A`, con las variables `VIGMIN_A` y `VIGFREQW_A` aportando un peso menor. En el caso de `y_respiratorio` es aún más notorio: `ANXEV`, y las variables demográficas `SEX_A` y `AGEP_A`, así como el índice de masa corporal `BMICAT_A`, son las variables más relevantes, y la carga de actividad física apenas contribuye. Habría que explorar la comorbilidad de diagnósticos de ansiedad y asma, ya que comparten algunos síntomas.

Los resultados relacionados con la importancia de las features en los modelos finales se encuentran en [la Tabla B.3](#), en el Apéndice B.

6 Productivización y Arquitectura

6.1. Justificación de arquitectura

Se decide crear una arquitectura en la nube de AWS, por su facilidad de acceso para empresas con productos de relojes inteligentes como Polar, Coros, Garmin, Suunto, Fitbit y otras. Al tener el servicio de predicción de riesgo disponible en una API, dichas empresas pueden enviar los datos de un usuario de manera estándar mediante un documento JSON y obtener no solo la predicción de riesgo general, sino también la de los tres dominios, incluidos en el riesgo compuesto.

6.2. Acceso al modelo

El servicio de predicción de riesgo compuesto se hace disponible a través de un API endpoint disponible en AWS mediante el servicio de API Gateway, con dos versiones: desarrollo y producción. Las compañías creadoras de relojes inteligentes pueden enviar los datos de sus usuarios mediante la construcción de documentos JSON que incluyan la lista de features requerida por el endpoint y el modelo, incluyendo no solo los datos de actividad física obtenidos en el dispositivo del usuario, sino también información parte del perfil de usuario.



Fig. 5: Acceso al producto mediante API

La llamada a la API retorna un documento JSON con esta estructura:

```
{"risk_score": "low", "risk_score_lesion": "low",  
  "risk_score_malestar_psicologico": "low", "risk_score_respiratorio": "low"}
```

Una vez el API procesa los datos recibidos, los envía a una función Lambda en AWS, correspondiente al ambiente del endpoint, en la cual se hace uso de los algoritmos de limpieza de datos, los modelos serializados y la lógica de cálculo de riesgo compuesto.

6.3. Diseño del pipeline en AWS

El pipeline para productivizar el modelo utiliza tecnologías como GitHub para el manejo de versiones y la ejecución de dicho pipeline, Terraform como herramienta IaC de despliegue de infraestructura en la nube y AWS como proveedor de servicios en la nube.




Fig. 6: Pilar de control de versiones y CICD

Se creó un [repositorio en GitHub](#) [A.1], así como una estrategia de branching para el desarrollo del código en Git, utilizando versiones distintas para las fases de EDA, Feature Engineering, Model Tuning, productivización del modelo, así como para el desarrollo de infraestructura y el pipeline de CI/CD.

Dicho versionamiento utilizando el feature de `git worktree` para cada branch, permitió el trabajo simultáneo en todas ellas, eliminando la posibilidad de bloqueo en el workflow.

```
$ git worktree list
/Users/Irina/TFM/tfm-wearable-health      68156de [feature/modeltuning]
/Users/Irina/TFM/tfm-wearable-health-cicd 1e45c0e [feature/cicd]
/Users/Irina/TFM/tfm-wearable-health-infra 6224cd0 [feature/infra]
/Users/Irina/TFM/tfm-wearable-health-product dc1a66e [feature/product]
```


Se definieron dos ambientes distintos, uno de desarrollo y otro de producción, de manera que se puedan validar los cambios en desarrollo antes de promoverlos al ambiente disponible para las

compañías de relojes inteligentes. En cada ambiente se cuenta con una versión del código de GitHub y un pipeline de despliegue en AWS correspondiente.

El trigger del pipeline está automatizado para que al hacer merge de un Pull Request en GitHub, ya sea al branch de develop o al main, comience el pipeline a inicializar, verificar y aplicar los cambios de infraestructura mediante Terraform en la cuenta de AWS configurada, creando nuevas imágenes de contenedor de Docker, publicándolas en el repositorio de AWS Elastic Container Repository (ECR), creando dos funciones AWS Lambda que hacen uso de dichas imágenes, así como los API endpoints de AWS APIGateway.

Las funciones Lambda, además, contienen los scripts de limpieza de datos, entrenamiento de modelos, predicción de riesgos de los 3 dominios seleccionados y el cálculo de riesgo compuesto basado en los resultados de cada modelo, así como los modelos ya serializados con `pickle`.

Figura 7: Llamada de prueba a API (URLs en [A.5](#))



```
nina@ninas-air:~  
Last login: Thu Sep 10 21:00:01 on ttys000  
(base) → ~ curl -X POST "https://9ev2nlb0ak.execute-api.us-east-2.amazonaws.com  
/dev/predict" \  
-H "Content-Type: application/json" \  
-d '{  
  "SEX_A": 2,  
  "AGE": 34,  
  "HEIGHT": 165,  
  "HEIGHT_UNIT": "cm",  
  "WEIGHT": 68,  
  "SLPHOURS": 7,  
  "DEPEV": 0,  
  "ANXEV": 0,  
  "ASEV": 0,  
  "MODMIN": 30,  
  "VIGMIN": 20,  
  "MODFREQ": 3,  
  "VIGFREQ": 2,  
  "STRFREQ": 1  
}'  
{  
  "risk_score": "medium",  
  "risk_score_lesion": "low",  
  "risk_score_malestar_psicol  
ogico": "medium",  
  "risk_score_respiratorio": "low"  
}
```

Podemos observar un diagrama completo de la arquitectura en la siguiente imagen:




Fig. 8: Imagen de la arquitectura de producto.

7 Conclusiones

7.1. Conclusiones e impacto de negocio

En cuanto a la predicción de riesgo de los distintos dominios: lesión deportiva, crisis respiratoria/asmática y malestar psicológico de depresión o ansiedad, los modelos entrenados demostraron una relación clara entre el nivel de actividad física semanal analizado en las variables `MOD_LEVEL` y `VIG_LEVEL` y la presencia de eventos positivos de riesgo, particularmente en el dominio de lesión deportiva, donde estas variables de carga tuvieron mayor importancia que las variables demográficas (edad, sexo), consistente con hallazgos previos sobre volumen de entrenamiento y riesgo de lesión [3, 8]. En los dominios de malestar psicológico y respiratorio, en cambio, el feature/permutation importance mostró el patrón inverso: los antecedentes de diagnóstico (ansiedad, depresión) y variables demográficas superaron a las variables de actividad física, sugiriendo que la carga de ejercicio por sí sola no captura suficientemente el riesgo de agudización en dichas condiciones crónicas preexistentes, en contraste con estudios como [4] y [10].

Inicialmente, por desbalance de clases, la estratificación escogida y la métrica para la selección en el GridSearch, la calidad de las predicciones no fue la esperada. Sin embargo, al aplicar distintas mejoras en esas áreas, se lograron obtener mejores resultados.

Dado que para cada usuario existen variables necesarias no capturadas por el reloj inteligente, como la edad, si tiene un diagnóstico, entre otros, deben incorporarse al perfil de usuario previa autorización, bajo el claro entendimiento por parte de él de que al brindar dicha información, estará logrando mejorar la predicción que obtendrá de los modelos de machine learning brindados como servicio de la compañía con o sin un costo adicional, dependiendo del modelo de negocio. La recomendación es proporcionar esta capacidad de forma gratuita a sus usuarios para lograr un mayor posicionamiento en el mercado y una ventaja competitiva.

Con respecto al pipeline de productivización, los resultados fueron positivos. El aplicar conocimiento de arquitectura en la nube, infraestructura como código y CICD no solo aceleró el proceso de desarrollo y evitó errores manuales, sino que también logró automatizar la prueba y el error de los distintos ambientes, así como acelerar la puesta en producción del producto de predicción.

7.2. Limitaciones

Originalmente se esperaba incluir mayor cantidad de condiciones crónicas en el modelo predictor, pero la calidad de los datos de NHIS no fue suficiente para lograrlo. En muchos casos se tenían variables sobre las condiciones crónicas pero no información sobre exacerbaciones recientes para comparar, o viceversa. Con una encuesta más completa o mejor estructurada, esto sería más sencillo de lograr. El dataset de NHIS, por su naturaleza, no incluye datos de exacerbaciones recientes de algunos de los grupos de condiciones crónicas, como para todas las variables de eventos cardiovasculares, autoinmunes, inflamatorios o metabólicos, sino únicamente la preexistencia de la condición. Por dicha situación, durante el proceso de EDA se descartó la creación de submodelos para cada condición crónica y se continuó únicamente con las condiciones de depresión, ansiedad y asma, así como lesiones específicamente deportivas.

Otra limitación es la utilización del modelo Kessler K6 para la variable objetivo `y_malestar_psicologico`. Este modelo utiliza 6 columnas del dataset, pero la mayoría están más relacionadas con la depresión que con la ansiedad. Otra situación es que según estudios [4, 6], la cantidad y el tipo de actividad física para cada condición pueden tener resultados inversos,

por lo cual sería prudente crear modelos distintos para cada condición y medirlas con un modelo distinto a Kessler, que distinga entre ellas. Sin embargo, al filtrar los datos de NHIS24, se descartó dividir las poblaciones y se optó por agrupar ambas en un dominio conjunto de salud mental o malestar psicológico.

7.3. Mejoras futuras del producto.

Una de las mejoras identificadas fue alimentar los algoritmos con datasets más específicos para cada modelo. Ya se divide la modelización del score de riesgo por variable objetivo. Explorando más las fuentes disponibles públicamente o de manera privada, se podría conseguir un mejor rendimiento en los modelos generados.

Una mejora puntual es ajustar los hiperparámetros para obtener métricas aún más deseables, o manejar el desbalanceo de clases en los modelos ajustando de forma diferente los hiperparámetros de `scale_pos_weight` y `class_weight`. También es posible explorar una métrica más avanzada para la selección de los mejores estimadores, como se hizo con `f2_score`.

Otra incorporación al pipeline de CICD es almacenar resultados de predicciones realizadas, para reentrenar los modelos con una mayor cantidad de datos. Finalmente, otra mejora es analizar si el resultado de los modelos debería ser un score de riesgo numérico, como al modelar el riesgo crediticio, y que fuese cada compañía de relojes inteligentes la que decidiese qué umbrales utilizar y cómo mostrar el riesgo en su sistema.

8. Bibliografía

1. Bull FC, Al-Ansari SS, Biddle S, et al. World Health Organization 2020 guidelines on physical activity and sedentary behaviour. *Br J Sports Med.* 2020;54(24):1451-1462. <https://doi.org/10.1136/bjsports-2020-102955>
2. Kessler RC, Andrews G, Colpe LJ, et al. Short screening scales to monitor population prevalences and trends in non-specific psychological distress. *Psychol Med.* 2002;32(6):959-976. [doi:10.1017/S0033291702006074](https://doi.org/10.1017/S0033291702006074)

3. Kreher JB, Schwartz JB. Overtraining syndrome: a practical guide. *Sports Health*. 2012;4(2):128-138. <https://doi.org/10.1177/1941738111434406>
4. Munro NR, Teague S, Somoray K, et al. Effect of exercise on depression and anxiety symptoms: systematic umbrella review with meta-meta-analysis. *Br J Sports Med*. 2026;60:590-599. <https://doi.org/10.1136/bjsports-2025-110301>
5. National Center for Health Statistics. National Health Interview Survey, 2024. Public-use data file and documentation. 2025. <https://www.cdc.gov/nchs/nhis/documentation/index.html>
6. Noetel M, Sanders T, Gallardo-Gómez D, et al. Effect of exercise for depression: systematic review and network meta-analysis of randomised controlled trials. *BMJ*. 2024;384:e075847. <https://doi.org/10.1136/bmj-2023-075847>
7. Prochaska JJ, Sung HY, Max W, Shi Y, Ong M. Validity study of the K6 scale as a measure of moderate mental distress based on mental health treatment need and utilization. *Int J Methods Psychiatr Res*. 2012;21(2):88-97. [doi:10.1002/mpr.1349](https://doi.org/10.1002/mpr.1349)
8. Schuster Brandt Frandsen J, Hulme A, Parner ET, et al. How much running is too much? Identifying high-risk running sessions in a 5200-person cohort study. *Br J Sports Med*. 2025;59:1203-1210. <https://doi.org/10.1136/bjsports-2024-109380>
9. van der Worp MP, ten Haaf DSM, van Cingel R, et al. Injuries in runners; a systematic review on risk factors and sex differences. *PLoS One*. 2015;10(2):e0114937. <https://doi.org/10.1371/journal.pone.0114937>
10. Xiong T, Bai X, Wei X, et al. Exercise rehabilitation and chronic respiratory diseases: effects, mechanisms, and therapeutic benefits. *Int J Chron Obstruct Pulmon Dis*. 2023;18:1251-1266. <https://doi.org/10.2147/COPD.S408325>

Anexos

Apéndice A: Recursos Externos y Código

Para garantizar la reproducibilidad de este trabajo, el código fuente, la documentación técnica y los materiales multimedia están disponibles en los siguientes repositorios:

A.1 Repositorio de GitHub del proyecto:

<https://github.com/anairinac/tfm-wearable-health>

A.2 Jupyter Notebook:

<https://github.com/anairinac/tfm-wearable-health/blob/main/notebooks/notebook.ipynb>

<https://github.com/anairinac/tfm-wearable-health/blob/main/docs/notebook.html>

A.3 Vídeo de presentación del TFM:

<https://github.com/anairinac/tfm-wearable-health/blob/main/videos/tfm.mp4>

A.4 Codebook de variables de la encuesta NHIS2024:

https://github.com/anairinac/tfm-wearable-health/blob/main/docs/NHIS_2024_variables_codebook.xlsx

A.5 APIs de producto

Dev: <https://9ev2nlboak.execute-api.us-east-2.amazonaws.com/dev/predict>

Prod: <https://9ev2nlboak.execute-api.us-east-2.amazonaws.com/prod/predict>

Apéndice B: Documentación Técnica de Soporte

Tabla B.1 Preprocesador de transformación de columnas

```

numeric_transformer = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler())
])

robust_transformer = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', RobustScaler())
])

categorical_transformer = Pipeline([
    ('imputer', SimpleImputer(strategy='constant', fill_value=-1)),
    ('encoder', OneHotEncoder(drop='if_binary', handle_unknown='ignore'))
])

ord_categories = ['sin', 'insuficiente', 'minimo', 'supera']
ordinal_transformer = Pipeline([
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('encoder', OrdinalEncoder(categories=[ord_categories,
ord_categories]))
])

preprocessor = ColumnTransformer([
    ('num', numeric_transformer, num_std_features), # numeric
    ('num_outlier', robust_transformer, num_outlier_features), # num
outliers in activity duration features
    ('cat', categorical_transformer, cat_std_features), # categoric
    ('ord', ordinal_transformer, cat_ordinal_features) # ordinal cat
])

```

Tabla B.2 Resultado de métricas para modelos descartados (sin MSSS)					
Variable	Modelo	Accuracy	Recall	Precision	F1
y_lesion_deportiva	XGBoost	0.9808	0.00	0.00	0.00
y_lesion_deportiva	RandomForest	0.9808	0.00	0.00	0.00
y_respiratorio	RandomForest	0.7386	0.00	0.00	0.00
y_respiratorio	XGBoost	0.7406	0.0271	0.5833	0.0519
y_malestar_psicológico	RandomForest	0.7716	0.5228	0.5048	0.5116

Tabla B.3 Importancia de features para los modelos finales		
y_lesion_deportiva - XGBClassifier - roc_auc	y_malestar_psicologico - RandomForestClassifier - f1_macro	y_respiratorio - RandomForestClassifier - roc_auc
VIGMIN_A 0.071931 DEPEV_A 0.018697 STRFREQW_A 0.017280 AGEP_A 0.008691 MODMIN_WEEKLY 0.007040 MODMIN_A 0.003207 ANXEV_A 0.002510 ASEV_A 0.002118 HEIGHT_CM 0.002056 VIGFREQW_A 0.000555 CANT_VIGFREQW_A 0.000053 SEX_A 0.000030	DEPEV_A 0.074715 ANXEV_A 0.039903 VIGMIN_A 0.005079 VIGFREQW_A 0.002798 AGEP_A 0.002538 MODFREQW_A 0.002421 VIGMIN_WEEKLY 0.000749 ASEV_A 0.000465 BMICAT_A 0.000212 MODMIN_WEEKLY 0.000171 SEX_A 0.000082 CANT_VIGFREQW_A 0.000039	ANXEV_A 0.050775 SEX_A 0.022183 AGEP_A 0.010592 BMICAT_A 0.005475 DEPEV_A 0.004593 SLPHOURS_A 0.003081 HEIGHT_CM 0.003046 VIGMIN_A 0.000807 MOD_LEVEL 0.000633 MODMIN_WEEKLY 0.000268 STRFREQW_A 0.000071 ASEV_A 0.000000

CANT_MODFREQW_A 0.000000	CANT_STRFREQW_A -0.000068	VIGFREQW_A -0.000125
CANT_STRFREQW_A 0.000000	CANT_MODFREQW_A -0.000104	VIGMIN_WEEKLY -0.000137
MOD_LEVEL 0.000000	MOD_LEVEL -0.000384	CANT_STRFREQW_A -0.000174
VIG_LEVEL 0.000000	VIG_LEVEL -0.000532	VIG_LEVEL -0.000441
VIGMIN_WEEKLY -0.000004	STRFREQW_A -0.000927	CANT_VIGFREQW_A -0.000455
MODFREQW_A -0.000031	HEIGHT_CM -0.001122	CANT_MODFREQW_A -0.000514
SLPHOURS_A -0.000920	MODMIN_A -0.001886	MODMIN_A -0.001321
BMICAT_A -0.005566	SLPHOURS_A -0.002006	MODFREQW_A -0.001395

Tabla B.4 Construcción de variables objetivo

y_lesion (descartada)	y_lesion_deportiva	y_malestar_psicologico	y_respiratorio
<pre>df_eda['lesion_repentina'] = np.where(df_eda['ANYINJURY_A'] == 2, 0, np.where(df_eda['INJLIMIT_A'] == 2, 1, np.where(df_eda['INJSAWDOC_A'] == 2, 2, np.where((df_eda['INJSAWDOC_A'] == 1) </pre>	<pre>df_eda['y_lesion_deportiva'] = np.where(df_eda['INJSPORTS_A'] == 1, 1, 0)</pre>	<pre># --- Escala K6 (malestar psicológico) --- # 'SAD_A': {1: 'Todo el tiempo', 2: 'Casi siempre', 3: 'Algunas veces', 4: 'Rara vez', 5: 'Nunca'}, def calculate_k6_score(n_sad, n_nerv, n_rest, n_hope, n_eff, n_worth): cols = [n_sad, n_nerv,</pre>	<pre>df_eda['y_respiratorio'] = np.where(df_eda['ASAT12M_A'] == 1, 1, np.where(df_eda['ASAT12M_A'] == 2, 0, np.nan))</pre>

<pre> (df_eda['INJER_A'] == 1) (df_eda['INJHOSP_ A'] == 1) (df_eda['INJBONES _A'] == 1) (df_eda['INJSTITC H_A'] == 1), 3, np.nan))) df_eda['lesion_re petitiva'] = np.where(df_eda['REPSTRAIN _A'] == 2, 0, np.where(df_eda['REPLIMIT_ A'] == 2, 1, np.where(df_eda['REPSAWDOC _A'] == 2, 2, np.where(df_eda['REPSAWDOC _A'] == 1, 3, np.nan)))) </pre>		<pre> n_rest, n_hope, n_eff, n_worth] if any(pd.isna(col) for col in cols): return np.nan else: return sum(5 - col for col in cols) k6_cols = ['SAD_A', 'NERVOUS_A', 'RESTLESS_A', 'HOPELESS_A', 'EFFORT_A', 'WORTHLESS_A'] k6_score = df_eda.apply(lamb da row: calculate_k6_scor e(row['SAD_A'], row['NERVOUS_A'], row['RESTLESS_A'] , row['HOPELESS_A'] , row['EFFORT_A'], row['WORTHLESS_A']), axis=1) df_eda['k6_score'] = k6_score df_eda['y_malesta r_psicologico'] = pd.cut(k6_score, [0, 5, 13, 25], </pre>	
--	--	---	--

<pre> tbi_general = np.where(df_eda['TBIHLSBMC _A'] == 1, 1, np.where(df_eda['TBIHLSBMC _A'] == 2, 0, np.nan)) tbi_peligro = np.where(df_eda['TBILCDCMG _A'] == 1, 1, np.where(df_eda['TBILCDCMG _A'] == 2, 0, np.nan)) tbi_evento = (df_eda['TBIHLSBM C_A'] == 1) (df_eda['TBILCDCM G_A'] == 1) tbi_eval = np.where(tbi_evento & (df_eda['TBIEVAL_ A'] == 1), 1, np.where(tbi_evento & (df_eda['TBIEVAL_ A'] == 2), 0, np.where(</pre>		<pre> labels=[0, 1, 2], right=False) </pre>	
---	--	--	--

<pre> ~tbi_evento, 0, np.nan))) df_eda['lesion_cerebral'] = tbi_general + tbi_peligro + tbi_eval df_eda['y_lesion'] = df_eda[['lesion_repentina', 'lesion_repetitiva', 'lesion_cerebral']] .max(axis=1) </pre>			
---	--	--	--




Figura B.2 Boxplot de GridSearch original para y_respiratorio




Figura B.3 Boxplot de GridSearch original para y_malestar_psicologico




Figura B.4 Boxplot de GridSearch MSSS con balanceo para y_lesion_deportiva




Figura B.5 Boxplot de GridSearch MSSS con balanceo para y_respiratorio




Figura B.6 Boxplot de GridSearch MSSS con balanceo para y_malestar_psicologico




Figura B.7 Boxplot de GridSearch MSSS con balanceo y f2_score para y_lesion_deportiva




Figura B.8 Boxplot de GridSearch MSSS con balanceo y f2_score para y_respiratorio




Figura B.9 Boxplot de GridSearch MSSS con balanceo y f2_score para y_malestar_psicologico




Figura B.10 Matrices de confusión para modelos iniciales descartados (sin MSSS)